

AI Master Project 5기

최종 발표

과제명 M365 팀 지식베이스 & 주간 인사이트 자동화 Agent

멘 티 박지용, 11229

멘 토 정영필

발표 영상 10분 이내 | 시연 영상 별도 제출 5분 이내

프로젝트 개요

권장 2분 이내

1. 문제 정의 (Vision / Problem)

어떤 문제를 해결하고자 했는가?

M365에 팀 활동(SharePoint·Teams)은 매주 누적되나 정리는 수작업에 의존. 매니저가 수십 개 채널·문서를 직접 탐색·취합해 회당 약 2시간 소요, 정보 검색도 매번 수 분 소요.

왜 이 문제가 중요한가? (비즈니스 임팩트)

- 매니저 1인 연 약 100시간(13 영업일) 단순 취합에 소모
- 수작업·LLM 모두 인명·수치 환각 발생 → 보고 신뢰도 저하
- 현안 파악 지연 → 의사결정 속도 저하 및 정보 비대칭

2. 핵심 기능 (Core Features)

무엇을 만들었는가?

M365 활동을 자동 수집·검증·분석해 주간 인사이트 리포트와 출처 기반 자연어 Q&A를 생성하는 멀티 에이전트.

에이전트 구성:

- Orchestrator** 의도분류·Foresight 5단계·A2A 라우팅
- Collector** MS Graph 3단계 fallback + PII 마스킹
- DataValidator** 충족성 검증 · Hard Abort(환각 차단)
- Analyst** 채널·트렌드 + 인물 온톨로지 구축
- Reporter** ToT 후보 3개 동시 생성 (gpt-5.4)
- QA** PoC 6기준 결정론 채점 + grounding
- Publisher** 대시보드 + Teams Adaptive Card

핵심 기술 스택:

- Azure OpenAI gpt-5.4 · RAG(SQLite+BM25, 의존성 0) · MCP(JSON-RPC 2.0) · FastAPI+SSE

핵심 성과 (Key Achievements)

2시간 → 38초

주간 보고 (99% ↓ · 약 190배)

ToT 후보 병렬 생성 · 실측 3회 35-38-40s

100%

환각·PII·인젝션 차단

채점 재현성 표준편차 0

6.5초 (캐시 0.3초)

자연어 Q&A 응답 — 문서 직접 탐색 수 분을 즉답으로

KPI	목표	달성	달성률
리포트 시간단축	50% ↓	99% ↓	초과
환각 감지	90% ↑	100%	초과
PII·인젝션 차단	95% ↑	100%	초과
채점 재현성	분산 최소	표준편차 0	달성

Key Message

"단순 ReAct를 넘은 Foresight·Tree of Thoughts·Self-Correction 3중 추론과 의존성 0 RAG로 — 주간 보고 2시간을 38초로, 환각을 0으로 만들었습니다."

기술 아키텍처 고려 사항

아키텍처 구성에 대한 핵심 결정 사항을 중심으로 설명하세요

01 LangGraph 오케스트레이션 + A2A 상호운용

선택 이유: 단순 ReAct는 long-horizon 일관성 상실, 단일 생성은 비결정성으로 품질 편차, QA 실패 시 비선형 순환 불가.

핵심 활용: 조건부엠티 plan→execute→reflect→respond로 6 에이전트 지휘. 역량을 MCP 서버(JSON-RPC 2.0)로 도구 8개 표준 노출+ 자연어 agent-talk — 외부 MCP에 의존하는 게 아니라 타 팀 에이전트가 이를 호출.재사용하는 A2A 상호운용(사일로 방지).

02 3중 Deep Reasoning (단순 ReAct 보완)

선택 이유: 단일 LLM 생성은 비결정성.환각 자가검증 불가. 생성과 검증을 분리하고 후보를 비교해야 품질 하한선이 안정.


핵심 성과: Foresight(실행 전 5단계 계획+시뮬레이션)
· Tree of Thoughts(후보 3개 → PoC 게이트 → 완성도 선택)
· Self-Correction(80점 미달 시 자가수정).

— ToT: Yao 2023 · Self-Refine: Madaan 2023 · Plan-and-Solve: Wang 2023

03 RAG(의존성 0) + 환각 방지 결정론 채점

선택 이유: 사내 VDI는 ChromaDB-onnxruntime 설치 불가. LLM 단일 생성은 인명·수치 환각, LLM 평가는 비결정성.

구현 포인트: 코사인+Okapi BM25 순수 Python 자체구현 (의존성 0, $\alpha=0.7$). 환각은 온톨로지 교차검증 + LLM-free 6기준 채점(재현성 0) + 가드레일·PII = 4층 방어. — RAG: Lewis 2020 · BM25: Robertson 2009



67건 자동 테스트(단위 12 · 단계 31 · 레드팀 24)로 전 계층 검증 · 모든 KPI 레벨 재현

운영 확장성: 시연은 FastAPI+SSE 웹, 운영은 Power Automate→OneDrive 무인 경로를 이미 지원

→ PA 스케줄 트리거로 사람 개입 없는 주간 자동 실행으로 확장.

핵심 기술 난제 (Hurdle) — 단순 ReAct / 단순 RAG로는 왜 안 되는가

- ① 단순 ReAct: 다단계에서 계획 일관성 상실 — 엉뚱한 Tool 호출 (나무만 보고 숲을 못 봄)
- ② 단순 RAG(코사인만): 정확 키워드(파일명·CVE 번호 등) 매칭 누락 — 의미는 가까운데 키워드가 어긋남
- ③ LLM 단일 생성: 실제 데이터에 없는 인명·수치 환각 (빈약할수록 더 지어냄)

엔지니어링 접근 방법

어떻게 해결했는가? (설계 결정)

단일 LLM 생성을 버리고 **생성(Reporter)–검증(QA)을 분리** 후 결정론화.

- ① Foresight 5단계 계획+시뮬레이션
- ② ToT 후보 3개 병렬 생성(PoC 게이트 후 완성도로 선택)
- ③ Self-Correction(점수 오를 때만 채택)
- ④ Hard Abort.

핵심 알고리즘 / 아키텍처 결정

환각 검증을 LLM이 아닌 **결정론 코드로** — 온톨로지 인명 교차검증 + 수치는 단위 보유 정량주장만 대조(오탐 제거), 6기준 가중합산(재현성 0). ToT 후보는 **PoC 게이트 통과 후 콘텐츠 완성도로 변별** 선택.

논문 레퍼런스: AutoGen(Wu 2023, 멀티에이전트) · Tree of Thoughts(Yao 2023) · Self-Refine(Madaan 2023) · Plan-and-Solve(Wang 2023) · RAG(Lewis 2020)

왜 이 접근이 필요했는가?

단순 ReAct는 다단계 일관성 상실, 단일 생성은 환각 자가검증 불가, LLM-as-Judge는 비결정성·아침 편향. '**생성(Reporter)**'과 '**검증(QA)**'을 분리하고 **채점을 결정론화**해야 — AI 출력을 사람이·평가자가 신뢰할 수 있습니다.

고수준 reasoning 로그

PLAN 5-step → **SIMULATE** → **BRANCH**×3(격리) → **EVALUATE**[88,85,78]
→ **SELECT** → **CRITIQUE**→**REVISE** (new>best 일 때만 채택)

결과 및 성과 (수치로 제시)

40%→0%

환각 인명 불일치 · 자동 감지 **100%** (GT 10건)
· 온톨로지 교차검증

99%↓

주간 보고 시간 (2시간 → 38초)
· ToT 후보 3개 병렬 생성: 순차 88초→38초

190배

처리 속도 (수작업 7,200초 → 38초)
· 채점 **표준편차 0** · 67건 자동 테스트로 라이브 재현